

Trabajo Práctico Final - Big Data y MLOps

Objetivo

El objetivo del trabajo práctico es que los estudiantes puedan aplicar las herramientas de MLOps aprendidas durante la cursada para el desarrollo de un modelo de machine learning sobre un conjunto de datos de Big Data.

Se espera que el trabajo integre de manera coherente las distintas etapas del ciclo de vida de un modelo, utilizando tecnologías vistas en clase.

Requisitos mínimos

- Utilizar PySpark para la construcción y procesamiento de datos.
- Implementar MLflow para la experimentación y comparación de modelos.
- Incluir métricas de evaluación de modelos utilizando alguna herramienta para tal fin (Evidently/Shap).
- Trabajar sobre un repositorio Git correctamente versionado.

Todos los pasos deben estar debidamente explicados y justificados en la Notebook.

Entregables

Descripción del conjunto de datos

Origen, características principales y justificación de su elección.

Análisis exploratorio de datos (EDA)

Estadísticas descriptivas, visualizaciones y hallazgos principales.

Preparación de datos

Limpieza, transformaciones y feature engineering.

Experimentación con modelos

Entrenamiento de modelos y uso de MLflow para registrar métricas y parámetros.

Selección del modelo final

Justificación basada en métricas y criterios técnicos.

Publicación del modelo

Registro en MLflow Model Registry o despliegue en Databricks.

Explicación de uso

Cómo utilizar el modelo y ejemplo de inferencia.

Evaluación del modelo

Métricas, interpretación de resultados y limitaciones.

Conclusiones finales

Aprendizajes, mejoras futuras y trabajo futuro.

Fecha de entrega: 20/4